



ugr

Universidad
de Granada

TRABAJO FIN DE GRADO INGENIERÍA INFORMÁTICA

Diseño, integración y evaluación de diferentes procesos de
procesamiento del lenguaje natural en español

Tokenizador, POS Tagger y Lematizador

Autor

M^a Cristina Heredia Gómez

Directores

Salvador García López



ESCUELA TÉCNICA SUPERIOR DE INGENIERÍAS INFORMÁTICA Y DE TELECOMUNICACIÓN

—
Granada, mes de 201

©2016 – M^a CRISTINA HEREDIA GÓMEZ
ALL RIGHTS RESERVED.

Diseño, integración y evaluación de diferentes procesos de procesamiento del lenguaje natural en español

Tokenizador, POS Tagger y Lematizador

RESUMEN

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Morbi commodo, ipsum sed pharetra gravida, orci magna rhoncus neque, id pulvinar odio lorem non turpis. Nullam sit amet enim. Suspendisse id velit vitae ligula volutpat condimentum. Aliquam erat volutpat. Sed quis velit. Nulla facilisi. Nulla libero. Vivamus pharetra posuere sapien. Nam consectetur. Sed aliquam, nunc eget euismod ullamcorper, lectus nunc ullamcorper orci, fermentum bibendum enim nibh eget ipsum. Donec porttitor ligula eu dolor. Maecenas vitae nulla consequat libero cursus venenatis. Nam magna enim, accumsan eu, blandit sed, blandit a, eros.

Quisque facilisis erat a dui. Nam malesuada ornare dolor. Cras gravida, diam sit amet rhoncus ornare, erat elit consectetur erat, id egestas pede nibh eget odio. Proin tincidunt, velit vel porta elementum, magna diam molestie sapien, non aliquet massa pede eu diam. Aliquam iaculis. Fusce et ipsum et nulla tristique facilisis. Donec eget sem sit amet ligula viverra gravida. Etiam vehicula urna vel turpis. Suspendisse sagittis ante a urna. Morbi a est quis orci consequat rutrum. Nullam egestas feugiat felis. Integer adipiscing semper ligula. Nunc molestie, nisl sit amet cursus convallis, sapien lectus pretium metus, vitae pretium enim wisi id lectus. Donec vestibulum. Etiam vel nibh. Nulla facilisi. Mauris pharetra. Donec augue. Fusce ultrices, neque id dignissim ultrices, tellus mauris dictum elit, vel lacinia enim metus eu nunc.

Palabras Clave: Procesamiento del lenguaje natural, Scala, tokenizador, pos etiquetado, lematizador

Contents

I	INTRODUCCIÓN Y MOTIVACIÓN	I
1.1	Introducción al PLN	I
1.2	Historia del PLN	6
1.3	Aproximaciones más comunes en PLN	7
1.4	Estado del arte	8
1.5	El pipeline Genérico	II
1.6	El pipeline de OpenNLP	17
1.7	Limitaciones	20
2	OBJETIVOS DEL TRABAJO	22
3	INTRODUCCIÓN A SCALA	25
4	PLANIFICACIÓN, ANÁLISIS Y DISEÑO	33
5	MATERIAL EMPLEADO	40
6	IMPLEMENTACIÓN Y PRUEBAS	43
7	CONCLUSIONES Y VÍAS FUTURAS	46
	APPENDIX A SOME EXTRA STUFF	49
	REFERENCES	56

Listing of figures

1.1	Posible árbol de gramática Constituyente	16
1.2	Posible árbol de gramática de Dependencias	16
1.3	Disponibilidad de herramientas e idiomas en Stanford CoreNLP	21

THIS IS THE DEDICATION.

Acknowledgments

LOREM IPSUM DOLOR SIT AMET, consectetur adipiscing elit. Morbi commodo, ipsum sed pharetra gravida, orci magna rhoncus neque, id pulvinar odio lorem non turpis. Nullam sit amet enim. Suspendisse id velit vitae ligula volutpat condimentum. Aliquam erat volutpat. Sed quis velit. Nulla facilisi. Nulla libero. Vivamus pharetra posuere sapien. Nam consectetur. Sed aliquam, nunc eget euismod ullamcorper, lectus nunc ullamcorper orci, fermentum bibendum enim nibh eget ipsum. Donec porttitor ligula eu dolor. Maecenas vitae nulla consequat libero cursus venenatis. Nam magna enim, accumsan eu, blandit sed, blandit a, eros.

1

Introducción y motivación

1.1 INTRODUCCIÓN AL PLN

El proyecto desarrollado se engloba en el campo del Procesamiento del lenguaje natural. El lenguaje natural es cualquier lenguaje usado por los humanos para comunicarse (Alemán, Inglés, Español, Hindi...). Dado que estos lenguajes se transmiten entre generaciones y van experimentando evoluciones, resulta difícil obtener reglas que los describan. (PLN) es, por tanto, el área de estudio y aplicación que engloba cualquier tipo de manipulación computacional del lenguaje natural.

Es decir, PNL abarca desde aplicaciones simples, como contar el número de ocurrencias de las palabras en un texto para comparar diferentes estilos de escritura, a aplicaciones más complejas, como comprender expresiones humanas completas para poder dar respuestas útiles a preguntas. Bird et al. ^[4] Como por ejemplo, el asistente Siri de iPhone.

La lingüística computacional o PLN comenzó en 1980, sin embargo en los últimos 20 años ha crecido enormemente, despertando un gran interés en el ámbito de la investigación científica pero también en el ámbito práctico, ya que cada vez son más los productos, especialmente los tecnológicos,

que incorporan algún tipo de aplicación basada en NLP. Por ejemplo, traductores como el traductor de Skype, o asistentes de voz inteligentes (Cortana de Microsoft, Google Now de Google o el ya mencionado Siri de Apple).

Este crecimiento en el campo del procesamiento del lenguaje natural se debe principalmente a que en los últimos años, con el uso de redes sociales como Facebook, SnapChat, Twitter, Google plus, Linked in... y de sitios web comerciales como Amazon o Booking, los usuarios han generado una gran cantidad de contenido mayoritariamente subjetivo, el cual se puede aplicar en muchos ámbitos como márketing, política, gestión de crisis, soporte, atención al cliente, etc. También han influido en su crecimiento el aumento de capacidad de procesamiento y cómputo que ha habido en los últimos años y el desarrollo de técnicas de machine learning más complejas y potentes.

En la actualidad, según lo descrito en Hirschberg & Manning^[15] éstas son algunas de las principales áreas en PLN:

TRADUCCIÓN AUTOMÁTICA

La traducción automática es el área del PLN que tiene como objetivo el empleo de software para ayudar a traducir de un lenguaje natural a otro, ya sea en texto o hablado. Ésto supone una gran dificultad, ya que para que una traducción sea correcta, no basta con traducir palabra a palabra, sino que hay que tener en cuenta el sentido de la palabra y el contexto de ésta, pues hay casos en los que la misma palabra significa varias cosas dependiendo del contexto. Por ejemplo, en las frases "*compra una lata de refresco*" y "*deja ya de dar la lata*" aparece la palabra *lata* desempeñando una función distinta:

En la primera frase, *lata* es un nombre, por lo que se entendería como un envase hecho de hojalata, mientras que en la segunda frase aparece como una locución verbal, por lo que se entendería como "molestar" o "importunar".

El campo de la traducción automática se empezó a estudiar a finales de 1950s, sin embargo inicialmente no tuvo mucho éxito debido a que los traductores contruidos eran sistemas basados en gramáticas escritas a mano. Fue a partir de 1990 y gracias a que los científicos de IBM consiguieron una cantidad suficientemente grande de frases de traducciones entre dos lenguajes, cuando construyeron un modelo probabilístico de traducción automática.

A partir de entonces se siguió investigando y se descubrieron los **traductores máquina basados en frases**, que en lugar de ir traduciendo palabra a palabra, detectaban los pequeños subgrupos de palabras que solían ir juntas y que tenían una traducción especial. Esto se utilizó para desarrollar el traductor de Google.

Actualmente, el estado del arte en este campo está en traductores máquinas que usan deep learning, entrenando un modelo de varios niveles para optimizar un objetivo (la calidad de la traducción), donde luego el modelo pueda aprender por sí mismo más niveles que le sean útiles para desarrollar la tarea. Esto ha sido estudiado especialmente para redes neuronales, habiendo conseguido en varios casos obtener los mejores resultados hasta el momento, empleando redes neuronales distribuidas. Como por ejemplo, en Luong et al.^[22].

SISTEMAS DE RECONOCIMIENTO DEL HABLA

Esta área, muy conocida desde 1980s, estudia como permitir y mejorar la comunicación entre humanos y máquinas. Aunque siempre se ha pensado, por ejemplo, en aplicaciones como robots que ayudan en casa o a personas con movilidad reducida, no muchos años atrás se expandió al ámbito de los smartphones (mencionábamos en la introducción a los asistentes de voz para móvil más conocidos).

El reconocimiento del habla necesita principalmente de :

- Una herramienta de reconocimiento automático del habla (RAH) para identificar que está diciendo el humano.
- Una herramienta de manejo de diálogo (MD) para identificar lo que quiere el humano.
- Acciones para realizar la actividad solicitada.
- Una herramienta de síntesis texto a voz para que la máquina pueda comunicar al humano el resultado de forma hablada.

Sin embargo, aún se está investigando como hacer estas herramientas más precisas. Añadiéndole a lo anterior las dificultades propias de reconocer lenguaje humano hablado: pausas, coetillas, coordinación, toma de turnos... desemboca en que los sistemas de reconocimiento de habla aún no

han tenido gran éxito interactuando en dominios abiertos, donde los usuarios pueden hablar de cualquier cosa, aunque en dominios cerrados donde conocían el tema han mostrado resultados mejores.

En los últimos años se ha aplicado deep learning en estos sistemas, mapeando señales de sonido a secuencias de palabras y sonidos del lenguaje humano Hinton et al.^[14], aunque actualmente el enfoque más usado es el proceso de decisión de Markov, que hace identificación del diálogo (pregunta, sentencia, acuerdo..) mediante una probabilidad de distribución sobre todos los posibles estados del sistema, que va actualizando según se desarrolla el diálogo. Young et al.^[44].

LECTURA AUTOMÁTICA

La lectura automática es el área que tiene como objetivo que las máquinas puedan integrar o resumir información a los humanos, mediante la lectura y comprensión de las grandes cantidades de texto disponibles.

Esta idea atrae especialmente a los científicos, ya que es complicado llevar el ritmo de todas las publicaciones que se hacen, aunque sólo sea en su campo, por lo que sería de gran utilidad que un sistema pudiera resumir e identificar los datos más relevantes de las publicaciones. El objetivo inicial de estos sistemas es la extracción de relaciones, es decir, ser capaz de extraer relaciones entre dos entidades, como por ejemplo "A es hermano de B", lo cual ya se ha realizado con éxito en dominios específicos. Aunque hay técnicas que escriben los patrones de las relaciones a mano (por ejemplo: <PERSONA>, el hermano de <PERSONA>), se ha demostrado que aplicando Machine learning se obtienen mejores resultados, ya que se pueden obtener relaciones basadas en características extraídas de secuencias de palabras y secuencias gramaticales de una frase. Culotta & Sorensen^[7].

Los sistemas más recientes han usado inferencia probabilística sofisticada para distinguir qué cláusulas textuales se asocian a qué factores de la base del conocimiento, por ejemplo, Niu et al.^[27] y apuestan por técnicas de extracción de hechos más simples pero más escalables que no requieren etiquetado manual de los datos, o los extraen usando NLP. Etzioni et al.^[10].

MINERÍA DE DATOS EN MEDIOS SOCIALES

La minería de datos es el campo que tiene como objetivo descubrir patrones en grandes volúmenes de datos. Hoy en día, la gran cantidad de datos disponibles a través de redes sociales (Facebook, Twitter, Instagram, Youtube..), blogs o foros se puede descargar usando técnicas de web scrapping y se usa, aplicando técnicas de machine learning e inteligencia artificial, para aprender a detectar información demográfica a partir del lenguaje (como sexo o edad), hacer un seguimiento de las tendencias más populares u opiniones más populares sobre política o sobre productos, e incluso, como hizo Google (www.google.org/flutrends/) para ver como se difunde la gripe a través de los tweets de los usuarios y sus búsquedas en internet Elhadad et al.^[9].

A pesar de que este campo tiene innumerables aplicaciones, muchas de las cuales podrían ser de gran interés (como por ejemplo, detectar grupos que hacen bullying a otros o fomentan el odio), están aumentando los problemas de privacidad y se está limitando el acceso a esos datos. Por ejemplo, Twitter ya ha limitado el periodo de tiempo del que se pueden descargar tweets. Instagram también a modificado su API con este propósito.

Otra dificultad con la que cuenta este campo, es la validación. Muchas veces no hay forma de comprobar que la información presente en internet es cierta, por ejemplo las reseñas sobre hoteles, productos o restaurantes. En la actualidad, Facebook está ideando un modelo para detectar noticias falsas en su red social. Aunque se ha probado a agregar información de distintas fuentes para intentar validar la información, de momento no ha tenido mucho éxito.

ANÁLISIS DE SENTIMIENTOS

Este campo (también conocido como minería de opiniones) analiza las opiniones, sentimientos, valoraciones, actitudes y emociones de la gente frente a entidades como productos, servicios, organizaciones, individuos, eventos, temas, cuestiones...

Liu^[21] emplea el término *opinión* para referirse al concepto de sentimiento, evaluación, valoración o actitud e información asociada (objetivo de la opinión o persona que da la opinión) en su totalidad, y el término *sentimiento* para referirse al sentido positivo o negativo subyacente en una opinión. Por ejemplo "*Apple lo está haciendo muy bien en esta economía pobre*" es una opinión que contiene

dos sentimientos, uno positivo con Apple como objetivo y otro negativo sobre la economía actual.

Los estudios sobre este campo comenzaron en el año 2000, principalmente debido a que para entonces se empezó a recoger texto subjetivo en formato digital. Actualmente hay muchos campos relacionados con este cuyas tareas difieren ligeramente, por ejemplo análisis de opiniones, análisis de subjetividad, minería de sentimientos... aunque gran parte del trabajo se concentra en el análisis de sentimientos.

Los enfoques más simples tratan de identificar si lo expresado en el texto (por ejemplo, en un tweet) tiene una orientación positiva o negativa usando diccionarios de sentimientos como Whissell^[41]. Otros enfoques más complejos tratan de identificar la polaridad del sentimiento así como el objeto de éste. Wiebe et al.^[42]. También se han realizado trabajos recientes tratando de indentificar algunas emociones en particular, como las de Ekman (furia, aversión, miedo, felicidad, tristeza y sorpresa) y se ha investigado sobre reconocer esas emociones clásicas usando características como la edad, la personalidad, el género las condiciones mentales o médicas del usuario. Hirschberg & Manning^[15].

Las aplicaciones de este campo son innumerables y abarcan desde identificar valoraciones en productos Wang^[39] a predecir los precios del mercado o evaluar el estado mental de una comunidad. Bollen et al.^[5].

1.2 HISTORIA DEL PLN

De acuerdo a lo descrito en Hirschberg & Manning^[15], el PLN comienza en 1980s como intersección entre la inteligencia artificial y la lingüística. Durante las primeras décadas, los investigadores escribían a mano las reglas y el vocabulario del lenguaje humano. Sin embargo, no se obtuvo éxito, debido a la variabilidad y dificultad del lenguaje humano. Por ejemplo, el traductor palabra a palabra de ruso a inglés que no tenía en cuenta el contexto, el léxico o la morfología y que tradujo la frase bíblica : *"El espíritu está dispuesto, pero la carne es débil"* como *"El vodka es agradable, pero la carne es estropeado"* según Nadkarni et al.^[26].

Es a partir de 1990 cuando el PLN sufre una transformación cuando los investigadores comienzan a tener la posibilidad de obtener grandes cantidades de datos del lenguaje en formato digital y construyen modelos sobre estos. Surge así el PLN estadístico o PLN basado en corpus, lo que supuso un éxito en el uso del "big data", aunque ese término se introduciría más adelante. Con lo anterior

surgen métodos que usan el PART-OF-SPEECH (POS) de las palabras, es decir, su categoría morfosintáctica (si son sustantivo, un adjetivo, un verbo, una preposición...) adquiriendo notables resultados cuando se entrena con un conjunto de datos suficientemente grande.

Actualmente, muchos clasificadores de texto y sentimientos se basan únicamente en los diferentes conjuntos de palabras que presenta el texto (bolsas de palabras) sin tener en cuenta estructuras a nivel de frase, de documento o de significado. Sin embargo, los mejores enfoques actuales usan técnicas sofisticadas de machine learning y un buen entendimiento de la estructura lingüística subyacente, identificando información sintáctica, semántica y de contexto. Algunos de los softwares más conocidos actualmente son:

- Stanford CoreNLP Manning et al.^[23] es una suite de herramientas de PLN basada en machine learning, que pueden ser incorporadas en aplicaciones con necesidades de procesamiento de texto. Desarrollada en Java y con algunas herramientas disponibles para los lenguajes más hablados, también incluye métodos para entrenar modelos sobre corpus de datos.
- Python NLTK Bird^[3] es una suite de PLN de las más completas. Programada en Python, soporta un gran número de librerías para texto que incluyen las herramientas más comunes. Su éxito se debe en parte a que está bien documentada, incluye tutoriales y a su comunidad activa de usuarios.

1.3 APROXIMACIONES MÁS COMUNES EN PLN

Debido a la gran aplicabilidad que tiene el análisis de sentimientos, se ha despertado un gran interés por este área del PLN, proponiendo en los últimos años numerosas aproximaciones que emplean varias técnicas desde diferentes áreas de la informática para resolver el problema.

En la actualidad, las aproximaciones más comunes son dos Ribeiro et al.^[31]:

1.3.1 APLICACIÓN DE MÉTODOS DE MACHINE LEARNING SUPERVISADOS

Estos enfoques aplican métodos de clasificación supervisada, por lo que tienen como desventaja que requieren de datos (corpus) etiquetados (con información morfosintáctica, lema...) para entrenar los clasificadores, lo que resulta costoso en tiempo dado que son cantidades grandes de datos.

De esta forma se consigue que los algoritmos aprendan de los datos etiquetados para luego ser capaces de clasificar otros datos de entrada. Como ventaja, estos métodos tienen la habilidad de adaptar y crear modelos entrenados para objetivos y contextos concretos.

1.3.2 APLICACIÓN DE MÉTODOS BASADOS EN LÉXICO

Estos enfoques tienen en común que emplean listas predefinidas de palabras, donde cada palabra está asociada a un sentimiento específico. Los métodos basados en léxico varían según el contexto en el que se crean, por ejemplo, LIWC Tausczik & Pennebaker^[36] fue originalmente propuesto para analizar patrones de sentimientos en textos formales escritos en inglés, mientras que PANAS-T Gonçalves et al.^[13] fue adaptado al contexto web.

A pesar de que no tienen la parte negativa de necesitar un conjunto de datos etiquetados, tienen la dificultad de crear un diccionario basado en léxico que sea aplicable en múltiples contextos.

1.4 ESTADO DEL ARTE

En la sección anterior se describían las aproximaciones más comunes actualmente en el análisis de sentimientos. Ya que tenemos una idea, en esta sección se ilustra brevemente el estado del arte.

En investigación, el análisis de sentimientos se ha desarrollado a tres niveles, según Liu^[21] y Westerski^[40]:

1.4.1 ANÁLISIS DE SENTIMIENTOS A NIVEL DE DOCUMENTO

El objetivo de este análisis es clasificar todos los sentimientos expresados por los autores a lo largo del documento, concluyendo si lo expresado en el documento es positivo, negativo o neutro, sobre una entidad que puede ser un producto o servicio. La mayoría de las técnicas de análisis de sentimientos a nivel de documento obtienen un acierto de clasificación entre el 70% y el 80%, cuando son aplicadas a un solo tipo de texto, dependiendo de la cantidad de texto que se tenga como entrada y del tipo de texto.

Algunos de las soluciones más destacadas en este área, son:

Por una parte, el trabajo desarrollado por Turney^[37] para clasificación de críticas, donde presenta un algoritmo de tres pasos que procesa los documentos sin supervisión humana. Este se basa en la

medida de la distancia entre los adjetivos encontrados en el texto a palabras preseleccionadas con polaridad conocida. Brevemente, los pasos que sigue son:

- Paso 1: Extrae los adjetivos del documento aplicando una serie de patrones predefinidos (como nombre-adverbio, nombre-adjetivo...etc)
- Paso 2: Mide la orientación semántica. Para ello se mide la distancia a palabras cuya polaridad se conoce ("excelente" y "pobre"). Obtiene la dependencia entre dos palabras analizando el número de ocurrencias con el motor de búsqueda **AltaVista** para documentos que contienen dos palabras relativamente próximas.
- Paso 3: Finalmente cuenta la orientación semántica media para todos los pares de palabras y clasifica la crítica como recomendada o no recomendada.

Por otro lado, Pang et al.^[30] presentaron otro trabajo basándose en técnicas conocidas de clasificación. En la propuesta se testea un grupo seleccionado de algoritmos de aprendizaje automático, comprobando si producen buenos resultados cuando se aplica el análisis de sentimientos a nivel de documento.

Presentan resultados para Naive Bayes Lewis^[20], Máxima entropía Berger et al.^[2] y Máquinas de soporte vectorial Joachims^[18], con un acierto de clasificación final de 71%-85%, dependiendo de la técnica y el conjunto de datos empleados.

1.4.2 ANÁLISIS DE SENTIMIENTOS A NIVEL DE ORACIÓN

Dos son los objetivos de este análisis: el primero es identificar si la frase contiene opiniones (es subjetiva) u objetiva. El otro es clasificar la frase si es subjetiva, en positiva, negativa o neutral. Al igual que el anterior nivel de análisis descrito, la mayoría de las soluciones propuestas a nivel de oración aplican técnicas de machine learning.

Entre los trabajos más conocidos centrados en encontrar frases subjetivas está Riloff & Wiebe^[32] donde propusieron un método que usa clasificadores de alta precisión basados en listas hechas de palabras indicativas de subjetividad, para extraer las oraciones subjetivas. En la primera fase del algoritmo, las frases con alto nivel de confianza son etiquetadas por dos clasificadores (primero, se etiquetan las subjetivas con alto nivel de confianza, y luego las objetivas con alto nivel de confianza).

Las frases que no tengan un alto nivel de confianza de pertenecer a una u otra categoría quedan sin etiquetar en esta primera fase.

En la segunda etapa del algoritmo, con los datos etiquetados obtenidos en la fase anterior se entrena un algoritmo de extracción que genera patrones para oraciones subjetivas, patrones que después son usados para buscar más sentencias subjetivas en el texto. Tras procesar todo el conjunto de datos de entrenamiento, se ordenan los patrones extraídos basándose en su ocurrencia, entre otras condiciones, y se toman los mejores para la siguiente iteración del análisis.

A diferencia de la técnica anterior, Yu & Hatzivassiloglou^[45] presentaron un trabajo en el que se clasificaba la frase en objetiva o subjetiva, pero también la orientación de las frases subjetivas (positiva, negativa o neutral). Para la primera, los autores presentan resultados para detección de similitud en oraciones, naive bayes y naive bayes multiclase. Para la segunda tarea, emplean una técnica similar a la de Turney^[37].

1.4.3 ANÁLISIS DE SENTIMIENTOS A NIVEL DE ASPECTO

Este nivel de análisis es el más detallado, lo que lo convierte en el más útil pero también el más complicado, ya que el objetivo no es solo determinar qué frases son objetivas o subjetivas y si estas últimas tienen orientación positiva, negativa o neutral, sino que también tiene como objetivo detectar qué es exactamente lo que le gusta o no al autor.

Una de las primeras soluciones más conocidas a este problema fue Hu & Liu^[16], un enfoque basado en el léxico que utilizaba la mayor frecuencia de las entidades, aspectos o servicios. Sobre éste se publica una mejora 4 años más tarde Ding et al.^[8], presentando así un método que funciona bastante bien en la práctica y consta de cuatro pasos:

- Paso 1. Marcar expresiones de sentimientos: consiste en marcar todas las expresiones de sentimientos en cada frase que contengan uno o más aspectos con +1 o -1. Por ejemplo: *"el altavoz de este teléfono no es bueno"* sería marcada con un (+1) dado que "bueno" es una palabra asociada a polaridad positiva.
- Paso 2. Aplicar desplazadores de sentimientos: esto son, palabras o frases que pueden cambiar la orientación del sentimiento. Por ejemplo, "no" es un desplazador. Ahora la frase anterior sería marcada con (-1).

- Paso 3. Manejo de palabras y frases adversativas: palabras y frases que indican contrariedad necesitan ser manejadas, ya que suelen cambiar la orientación de los sentimientos. Por ejemplo, "pero" o "sin embargo" son conjunciones adversativas. Un ejemplo de manejo sería "*el altavoz de este teléfono no es bueno (-1), sin embargo la cámara es estupenda (+1)*"
- paso 4. Agregar puntuación de los sentimientos: para ello se suele aplicar una función como

$$puntuacion(a_i, s) = \sum_{se_j} \frac{se_j.ss}{dist(se_j, a_i)}$$

donde se_j es la expresión de un sentimiento en la frase s , a_i es el aspecto (objeto, servicio...) i-ésimo de la frase s , $se_j.ss$ es la puntuación del sentimiento se_j y $dist(se_j, a_i)$ es la distancia entre el aspecto a_i y el sentimiento se_j en la oración s .

Si la puntuación final es positiva, entonces la opinión sobre el aspecto a_i en la frase s es positivo. Si la puntuación es negativa, la opinión sobre el aspecto es negativa. Si es 0, la opinión sobre ese aspecto es neutral.

También se han planteado métodos que usan aprendizaje automático en este nivel de análisis, como por ejemplo Jiang et al.^[17] que emplea un árbol de parseo sintáctico para generar un conjunto de características que representen algunas relaciones sintácticas de la entidad o aspecto objetivo, y otras palabras.

1.5 EL PIPELINE GENÉRICO

El objetivo final de toda suite de PLN es tener un software que contenga un conjunto de herramientas para poder realizar análisis de sentimientos o algún tipo de extracción de información. Esto se alcanza a través de varias tareas de procesamiento del texto, empezando por hacer el contenido uniforme y acabando por identificar las funciones de las palabras y como se organizan. Aquí se describen las tareas más comunes del pipeline de un software de PLN junto con las aproximaciones más comunes.

1.5.1 OBTENCIÓN DE DATOS

La obtención de datos es la primera tarea a realizar, mediante la cual se obtendrá el corpus de texto, etiquetado o no (depende de la aproximación a aplicar) que se va a usar para crear la herramienta de PLN, así como los datos sobre los que se quiere hacer el análisis de sentimientos o la extracción de información deseada.

La forma general de obtener los datos directamente de internet es a través de la propia API de los sitios web de los que se desee descargar información por ejemplo la Api de twitter si queremos descargar tweets, o la api de instagram para imágenes y etiquetas. Sin embargo, a pesar de que hay manuales que explican como consultarlas, estas APIs han limitado mucho las descargas últimamente, alegando cuestiones de privacidad de los datos de usuario. Otro método es usar arañas web para rastrear la información deseada de forma similar a lo que hace google con su conocida araña GOOGLE-BOT, con la que visita todas las webs frecuentemente para añadirlas a su índice y percatarse de los cambios. Ahora bien, este último método requiere unos conocimientos necesarios para crear una araña web y ocupa mucho ancho de banda.

En cuanto a corpus ya etiquetados en inglés se pueden encontrar muchos, entre los más populares están THE PENN TREEBANK Marcus et al.^[24] o WIKICORPUS <http://www.cs.upc.edu/~nlp/wikicorpus/>, mientras que para español son conocidos WIKICORPUS, ANCORA <http://clic.ub.edu/ancora> o SEMEVAL Màrquez et al.^[25].

1.5.2 PROCESAMIENTO DEL TEXTO

Teniendo el texto, se le aplica un procesamiento, separándolo en unidades relevantes, añadiendo información sintáctica y morfológica, extrayendo entidades y relaciones entre estas... En este apartado se describen las fases de procesamiento más comunes según describe Rodrigues & da Silva Teixeira^[33].

TOKENIZACIÓN

En esta fase se separa el texto del documento en sus unidades atómicas, los tokens (palabras, números, símbolos), por lo que es una fase totalmente necesaria en casi cualquier suite de PLN. Aunque no es una tarea muy compleja para lenguajes que emplean espacios entre palabras, como la mayoría de

lenguajes que usan el alfabeto latino, sí que resulta mucho más complicado en lenguajes que no usan espacios entre palabras, como el Chino. Chang et al.^[6].

La tokenización se sirve de heurísticas simples, como considerar que todos los strings de caracteres del alfabeto contiguos forman parte del mismo token (igualmente para los números) y que todos los tokens van separados unos de otros por espacios, saltos de línea o por signos de puntuación que no sean abreviaciones. Algunas herramientas actuales que hacen tokenización son Freeling Padró & Stanilovsky^[29], Apache OpenNLP Baldrige^[1] y los ya citados NLTK y StanfordNLP. No hay ninguna herramienta especialmente dedicada a tokenizar, ya que la tokenización puede ser razonablemente bien hecha usando expresiones regulares cuando se procesan lenguajes que usan el alfabeto latino. Para otros lenguajes más complejos, como el Árabe o el Chino, sí se precisan de tokenizadores más complejos, como el Stanford Word Segmenter que aplica segmentación de palabras.

DETECCIÓN DE LÍMITES DE ORACIONES

En esta fase se aborda el problema de establecer los límites de una oración en el texto. En algunos casos esto se incluye dentro de la fase de tokenización. Encontrar los límites de una oración no es una tarea trivial, ya que las marcas de puntuación que delimitan el final de una frase suelen ser ambiguas en muchos lenguajes. En español lo son, ya que por ejemplo, el punto se puede usar como marcador de final de oración pero también como separador entre parte entera y decimal en números reales o en iniciales y abreviaciones (por ejemplo, Srta.).

Algunos sisemas que han demostrado buenos resultados en separación de frases sobre diferentes lenguajes naturales, son Punkt Kiss & Strunk^[19] e iSentenizer Wong et al.^[43].

LEMATIZACIÓN

Lematización es el proceso mediante el cual se determina el lema de cada palabra. El lexema de una palabra se define como la unidad mínima que es parte común en todas las palabras de una misma familia. Por ejemplo, *"arte"*, *"artístico"* o *"artista"* son tres palabras distintas que comparten el lexema *"art"*. Lema es la representación de la forma canónica (o forma de diccionario) de los lexemas, y tiene por tanto significado. Por ejemplo, *"escribían"*, *"escribieron"* o *"escribirán"* son palabras derivadas de un mismo lexema cuyo lema es *"escribir"*.

Este proceso es importante porque reduce el número de términos a procesar, ya que muchos se reducen al mismo lema, acortando así la complejidad computacional del problema. La dificultad de este proceso varía dependiendo del lenguaje, resultando mucho más sencillo para lenguajes con una morfología inflexiva simple, como el Inglés, y complicándose más para lenguajes morfológicamente más ricos como el Español o el Alemán.

STEMMING

Este método es común en lugar de la lematización e incluso en algunos casos se incluye dentro de ésta o como complemento. El Stemming es un proceso simple mediante el cual se trata de reducir la palabra a su forma base eliminando sus sufijos. Se obtiene así una forma de la palabra que no es necesariamente la raíz de la palabra, pero que suele bastar, dado que palabras de la misma familia tienen esa parte en común, o un conjunto reducido de partes en común, si son palabras irregulares. Por ejemplo: *"sleep"*, *"sleeping"*, *"slept"*, *"sleeps"*... tienen en común el stem *"sleep"*, que es la forma base del verbo. En lenguajes con pocas inflexiones, como el Inglés, es muy probable que el lema y el stem coincidan. Sin embargo, en lenguajes con más inflexiones, como el Español, eso rara vez ocurre.

POS TAGGING

POS Tagging es un proceso muy importante en tareas de PLN, ya que etiqueta mediante algoritmos cada palabra con su PART-OF-SPEECH, es decir, con su categoría morfosintáctica (nombre, verbo, preposición, adjetivo...) junto a otras propiedades que dependen de esta. De hecho es necesario para realizar el parseo sintáctico (el paso posterior).

Aunque lo usual es aplicar un proceso de lematización o stemming antes de esta fase, hay sistemas que aplican primero esta fase, como el desarrollado en este proyecto.

Los principales desafíos que se presentan en esta etapa, son:

- Tratar la ambigüedad, dado que las palabras pueden desempeñar distinta función morfosintáctica y por tanto, tener diferentes POS tags dependiendo del contexto.
- Asignar una etiqueta morfosintáctica a palabras de las que el sistema no tiene conocimiento

Para tratar de solventar los problemas anteriores, normalmente se tiene en cuenta el contexto dentro de la frase de la palabra a etiquetar, y se selecciona la etiqueta morfosintáctica más probable dada esa palabra y su contexto.

Que sea una tarea muy necesaria hace que esté muy investigada, por lo que actualmente la precisión de etiquetado ronda el 90%, aunque esto se debe a que la precisión se mide en porcentaje de palabras bien etiquetadas. Si se midiera por porcentaje de frases completamente bien etiquetadas, la cifra descendería al 55%-57% de precisión, como manifestaban Giesbrecht & Evert^[11].

La mayoría de estas herramientas han sido desarrolladas para el Inglés y evaluadas usando los datos de Penn Treebank. Destacan por ejemplo Stanford POS Tagger que tiene modelos de etiquetado para 6 lenguajes diferentes, SVMTool Giménez & Marquez^[12] que se basa en clasificadores de máquinas de soporte vectorial y TreeTager, basado en modelos de Markov Schmid^[34].

PARSEO SINTÁCTICO

El parseo sintáctico es una tarea que consiste en analizar las oraciones para producir estructuras que representen como se organizan las palabras en las frases, dada una gramática formal. Las gramáticas tienen dos posibles formalismos estructurales:

- Constituyente: es una unidad dentro de una estructura jerárquica que está compuesta por una palabra o un grupo de palabras.
- De dependencia: estas gramáticas describen la estructura de una frase en términos de los enlaces entre las palabras, ya que cada enlace refleja una relación de dominancia/dependencia entre un término y otro dependiente de él. Estas gramáticas son las que normalmente se emplean para parsear texto.

Por ejemplo, para la frase "this books has two authors" ("este libro tiene dos autores")




Figure 1.1: Posible árbol de gramática Constituyente




Figure 1.2: Posible árbol de gramática de Dependencias

El parseo sintáctico una tarea computacionalmente muy intensiva, por lo que a veces es deseable sustituirla por otra menos costosa en cómputo que produzca resultados similares, como localizar patrones textuales. Sin embargo, esta sustitución no siempre es posible, dado que deben de tenerse fuentes de información semiestructuradas, estructuradas, o generadas por una máquina.

Algunas herramientas para parseo sintáctico son StanfordParser, MaltParser Nivre et al.^[28] o TurboParser <http://www.cs.cmu.edu/~ark/TurboParser/>, estas dos últimas implementan gramáticas de dependencias.

Aquí concluye la parte genérica del pipeline. Además del pipeline genérico, hay procesos que se engloban en una parte que se conoce como pipeline dependiente del dominio, algunos de los cuales se detallan en la siguiente sección.

1.6 EL PIPELINE DE OPENNLP

En la sección anterior vimos el pipeline genérico que suelen seguir los softwares de NLP. En esta se describe OpenNLP <http://opennlp.apache.org/>, un conocido framework desarrollado por Apache.

Apache OpenNLP es una librería desarrollada en Java que incorpora un kit de herramientas basadas en aprendizaje automático para hacer procesamiento del texto en lenguaje natural, permitiendo al usuario crear su propio pipeline de PLN, entrenar sus propios modelos o evaluarlos. Como consecuencia, no ofrece soporte para ningún lenguaje específico, sino que ofrece algoritmos bastante genéricos que podrían funcionar con cualquier lenguaje. Sí que tiene algunos modelos pre entrenados para algunos lenguajes.

1.6.1 HERRAMIENTAS QUE INCORPORA

las herramientas de OpenNLP son accesibles a través de su API o por línea de comandos. Estas son las herramientas que incorpora:

DETECTOR DE FRASES

Un detector de frases capaz de detectar si un signo de puntuación marca el final de una frase o no. Se entiende por frase la mayor secuencia de caracteres separados por espacios en blanco entre dos signos de puntuación. La frase inicial y final de un texto son excepcionales, los primeros caracteres que no sean caracteres en blanco se asumen como el inicio de una frase, mientras que los últimos caracteres no blancos se asumen como el final de la frase. Una vez que se han detectado correctamente las fronteras de las oraciones, se formatea el texto debidamente.

TOKENIZADOR

OpenNLP incorpora tres tokenizadores que segmentan una entrada de cadena de caracteres en tokens (palabras, signos, números..etc).

- Tokenizador de espacios en blanco: toma como tokens toda secuencia que no sean caracteres en blanco.

- Tokenizador simple: basado en clases de caracteres, donde las secuencias con la misma clase de caracter se consideran tokens.
- Tokenizador basado en aprendizaje: tokenizador de máxima entropía que detecta las fronteras de los tokens basándose en un modelo probabilístico.

DETOKENIZADOR

esta herramienta hace justo lo contrario que el tokenizador, es decir, construye el texto original no tokenizado a partir de una secuencia de tokens. La implementación se basa en reglas que definen como los tokens deben añadirse a la cadena de caracteres: *MERGE_TO_LEFT* añade el token por la izquierda, *MERGE_TO_RIGHT* añade el token por la derecha y *RIGHT_LEFT_MATCHING* añade el token a la derecha de la primera ocurrencia y a la izquierda de la segunda ocurrencia.

NER

(name entity recognition) es la herramienta que se encarga de buscar nombres de entidades y números en el texto. Para ello necesita un modelo que dependerá del lenguaje y el tipo de entidad que se quiera identificar. OpenNLP incluye algunos modelos pre entrenados sobre varios corpus libres disponibles. Para encontrar nombres en filas de texto, el texto debe ser previamente segmentado en frases y tokens.

CATEGORIZADOR DE DOCUMENTO

El categorizador de documento de OpenNLP puede clasificar texto dentro de categorías predefinidas. Se basa en un framework de máxima entropía. De nuevo, para clasificar el texto se necesita de un modelo, pero OpenNLP no provee de ninguno pre entrenado, dado que para clasificar se requiere de requisitos específicos.

POS TAGGER

El POS tagger que incorpora OpenNLP marca los tokens con su correspondiente tipo de palabra (según su categoría morfosintáctica) y para ello se basa en información del propio token y del con-

texto del mismo. Para resolver la ambigüedad que se presenta cuando un token puede tener múltiples etiquetas morfosintácticas, se aplica un modelo de probabilidad para predecir la etiqueta correcta. Para limitar el posible número de etiquetas que puede recibir un token, se emplea un diccionario de etiquetas.

Un *diccionario de etiquetas* es un diccionario de palabras donde se especifica qué etiquetas puede tener cada posible token.

CHUNKER

Esta herramienta separa el texto en sintagmas correlados, como el sujeto y el predicado de la frase, pero no especifica su estructura interna ni su función en la frase principal.

PARSEADOR

OpenNLP tiene dos implementaciones para el parseado: una llamada "chunking parser" que genera como salida el texto parseado separado por espacios, y el "tree insert parser" que genera un árbol como resultado, pero este último está aún en fase experimental. En ambos casos se requiere el entrenamiento de un modelo con datos en formato de OpenNLP (formato Penn treebank pero limitado a una frase por línea).

RESOLUCIÓN DE COREFERENCIAS

La resolución de coreferencias es una herramienta que incorpora OpenNLP para linkar las múltiples referencias que se hacen a una misma entidad a lo largo del documento, aunque se limita a menciones de sintagmas nominales, por ejemplo "el gato".

1.6.2 MODELOS QUE INCORPORA

Además de las herramientas anteriores, OpenNLP incorpora modelos preentrenados para los siguientes idiomas: Inglés, Alemán, Portugués, Danés, Holandés, Sueco y Español. <http://opennlp.sourceforge.net/models-1.5/>. Aunque en algunos enfoques se invierte el orden, todos los modelos aquí son entrenados aplicando primero detección de frases y luego tokenización (además de otras fases).

Para el Inglés incorpora modelos para todas las fases: tokenizador, detección de frases, pos Tagger, NER, chunker, parser y resolución de Coreferencias. Para el Sueco, Portugués, Alemán o Danés incluye tokenizador, detección de frases y pos Tagger, mientras que para el Holandés incluye los anteriores y además el NER. Para el Español, sólo incluye el NER.

1.7 LIMITACIONES

En Hirschberg & Manning^[15] dicen que la mayor limitación de los sistemas de PLN actuales es que dan soporte a los lenguajes más hablados y más extendidos, como el Inglés, Francés, Alemán, Español o Chino, pero otros como el Swahili, Bengali o Indonesio hablados por millones de personas no tienen disponible una herramienta de este tipo.

Sin embargo, aunque el Español está entre los focos de mira de las suites de PLN más usadas actualmente, rara vez hay un pipeline completo para análisis de sentimientos en español que proporcione resultados similares a los que se obtienen para el Inglés. Por ejemplo, en la sección anterior explicábamos [Apache OpenNLP](#), que directamente no incluye herramientas como lematización o análisis de sentimientos para ningún idioma.

Quizá la suite de NLP más conocida en la actualidad y referenciada junto con [Python NLTK](#) es [Stanford CoreNLP](#), debido a que es bastante completa, está bien documentada y tiene módulos para muchos de los idiomas más usados:

ANNOTATOR	AR	ZH	EN	FR	DE	ES
Tokenize / Segment	✓	✓	✓	✓		✓
Sentence Split	✓	✓	✓	✓	✓	✓
Part of Speech	✓	✓	✓	✓	✓	✓
Lemma			✓			
Named Entities		✓	✓		✓	✓
Constituency Parsing	✓	✓	✓	✓	✓	✓
Dependency Parsing		✓	✓	✓	✓	
Sentiment Analysis			✓			
Mention Detection		✓	✓			
Coreference		✓	✓			
Open IE			✓			

Figure 1.3: Disponibilidad de herramientas e idiomas en Stanford CoreNLP

Pero de nuevo vemos que sólo está completo para Inglés, faltando métodos como la lematización o el análisis de sentimientos para Español. Otro paquete menos conocido que incluye funcionalidad para minería web, procesamiento del lenguaje natural y machine learning es **Pattern** Smedt & Daelemans^[35] implementada en Python, que según el benchmark de métodos de análisis de sentimientos que hicieron Ribeiro et al.^[34] da mejores resultados en media que Stanford CoreNLP, aunque el benchmark solo hace comparaciones para el Inglés.

Pattern incluye una serie de herramientas para Español, pero esta tampoco incluye análisis de sentimientos para este lenguaje.

Ante estas limitaciones el proyecto desarrollado en este trabajo se centra en implementar las tres primeras etapas del pipeline de un software NLP para análisis de sentimientos en español: tokenizador, lematizador y POS tagger.

Teniendo como finalidad a largo plazo construir un software que haga como etapa final análisis de sentimientos en Español.

2

Objetivos del trabajo

Como se mencionó al final de la sección anterior, en este trabajo se implementan las tres primeras herramientas para un software de PLN en Español. El trabajo se implementa usando el lenguaje **Scala**, a partir de las propuestas de Smedt & Daelemans^[35] y Se puede consultar una planificación temporal de los objetivos del trabajo en la parte de resolución del trabajo, en el capítulo 4, sección de Planificación. Igualmente se puede consultar una introducción a **Scala** en esta parte, en el capítulo 3.

Los objetivos del trabajo se detallan brevemente a continuación de manera lineal:

DOCUMENTACIÓN Y REVISIÓN BIBLIOGRÁFICA

Aquí el objetivo es adquirir conocimiento general sobre la temática del procesamiento del lenguaje natural, tokenización, lematización y pos etiquetado para Español, documentarse sobre qué trabajos se han realizado anteriormente, la metodología a seguir, qué trabajos hay ahora y el estado del arte.

ELECCIÓN DE TÉCNICAS A IMPLEMENTAR Y LENGUAJE, PLANIFICACIÓN, ANÁLISIS DE REQUISITOS Y DISEÑO

El segundo objetivo consiste en:

- elegir tres técnicas: de tokenización, Pos tagger y lematización respectivamente. Finalmente se decide implementar las tres técnicas para estas herramientas que presenta Smedt & Daelemans^[35] para español.
- elegir el lenguaje de programación: se elige el lenguaje Scala para la implementación de este trabajo por sus múltiples ventajas a pesar de que su estructura resulta inicialmente compleja. Esta decisión se detalla en el capítulo resolución del trabajo, en la parte de Introducción a Scala.
- realizar un análisis de los requisitos y de diseño de las herramientas a implementar y su integración conjunta. Se detalla dentro del capítulo de resolución del trabajo, en la parte de Análisis y diseño.

IMPLEMENTACIÓN EN CÓDIGO, INTEGRACIÓN Y EVALUACIÓN DE LAS TÉCNICAS IMPLEMENTADAS

Aquí se implementan los diferentes módulos de tokenización, etiquetado morfosintáctico y parseo, siguiendo un desarrollo guiado por pruebas (TDD) escribiendo primero los test, usando para ello la librería Scalatest y el estilo FunSuite. Esto se detalla en el capítulo de resolución del trabajo, en la parte de implementación y pruebas.

ANÁLISIS Y EXPOSICIÓN DE RESULTADOS, COMPARACIONES Y CONCLUSIÓN

Aquí se discuten y analizan los resultados obtenidos, comparandolos con los del paper original y con los de otros softwares de NLP disponibles, y se exponen vías futuras del mismo. Se detalla en el capítulo conclusiones y vías futuras.

Resolución del trabajo

En esta parte del trabajo se detalla el desarrollo del trabajo. La resolución del trabajo se divide de la siguiente manera:

- En el **Capítulo 3** se hace una introducción a Scala, para visualizar el porqué de su elección.
- En el **Capítulo 4** se habla de como se ha planificado el proyecto, análisis de requisitos, diseño y metodología de desarrollo.
- En el **Capítulo 5** se explica el material empleado para la resolución de este trabajo, corpus de datos, ficheros para el contexto, el léxico o la morfología...
- En el **Capítulo 6** se detalla el proceso de implementación y pruebas de los algoritmos desarrollados.

*"If I were to pick a language to use today other than Java,
it would be Scala."*

James Gosling

3

Introducción a Scala

SCALA, (Scalable language) es un lenguaje de programación de propósito general cuya primera versión fue lanzada en 2004, y desde entonces ha ido creciendo enormemente en usuarios. Estas son algunas razones por las que se decide usar Scala en este proyecto Wampler & Payne^[38]:

ES ESCALABLE

Tal y como su nombre indica, este lenguaje ha sido diseñado para crecer con las demandas de sus usuarios, por lo que es una buena opción para escribir desde scripts pequeños a grandes sistemas, abordar desafíos actuales como el Big data o proporcionar servicios con gran disponibilidad y robustez. Esta es la principal razón por la que se escoge este lenguaje para este proyecto, dado que la intención es ir ampliándolo.

SOPORTA UN PARADIGMA MIXTO

Por una parte Scala soporta programación orientada a objetos (POO), mejorando los objects de Java incluyendo los traits, una forma clara de implementar los tipos usando composiciones mixtas. En Scala todo son objetos realmente, incluso los tipos numéricos. Por otro lado, también soporta totalmente programación funcional (FP), herramienta que se ha convertido en la mejor forma de pensar en concurrencia, Big data y corrección del código en general (empleo de inmutabilidad, funciones de primera clase, funciones de alto orden...).

TIENE UN SOFISTICADO SISTEMA DE TIPOS

Extiende el sistema de tipos de Java con otros tipos genéricos más flexibles y otras mejoras para mejorar la corrección del código. Además Scala incorpora un mecanismo de inferencia de tipos.

ES ESTATICAMENTE TIPADO

Scala incorpora el tipado estático como herramienta para crear aplicaciones más robustas, pero añade algunas modificaciones para hacerlo más llevadero, como incorporar la inferencia de tipos y hacerlo más flexible, permitiendo identificación de patrones y nuevas formas de escribir y componer tipos.

UN LENGUAJE JVM Y JAVASCRIPT

Explota las funcionalidades y optimizaciones de JVM, así como la gran cantidad de librerías y herramientas disponibles para Java. Además tiene un puerto para JavaScript (Scala.js).

SINTAXIS CONCISA, ELEGANTE Y FLEXIBLE

Si de algo hablan los programadores de Scala es de su sintaxis y de las reducciones de código que experimentan con respecto a Java. Por ejemplo:

```
// código en Java
class Persona {
    private int edad;
```

```

    private String nombre;

    public Persona(int edad, String nombre) {
        this.edad = edad;
        this.nombre = nombre;
    }
}

```

```

// código en Scala
class Persona(edad: Int, nombre: String)

```

Sí, dado este código en Scala el compilador creará dos atributos privados `edad`(entero) y `nombre`(cadena de caracteres) y un constructor que tomará los valores que se le pasen inicialmente para inicializar esas variables. Más rápido de escribir, de leer, y menos errores.

MÁS EJEMPLOS DE SCALA

A continuación se muestran algunos ejemplos simples de Scala obtenidos de ^[1]

3.0.1 ENCONTRAR CARACTER EN MAYÚSCULA

Éste es un ejemplo en Java y Scala del problema de encontrar un caracter en mayúscula en una cadena de texto:

```

// código en Java
boolean hasUpperCase = false;
for(int i = 0; i < name.length(); i++) {
    if(Character.isUpperCase(name.charAt(i))) {
        hasUpperCase = true;
        break;
    }
}

// código en Scala
val hasUpperCase = name.exists(_.isUpper)

```

Mientras que el código en Java itera sobre cada caracter del string, comprobando uno a uno hasta que encuentra una mayúscula, modifica el flag booleano y se sale del bucle, en Scala basta con llamar a la función `exist` sobre el string `name`, devolviendo un booleano. La `_` representa cada caracter de la cadena. De nuevo Scala seduce con su sintaxis.

3.0.2 CONTAR LAS LÍNEAS DE UN FICHERO

```
# código en Ruby
count = 0
File.open "someFile.txt" do |file|
  file.each { |line| count += 1 }
end
```

```
// código en Scala
val count = scala.io.Source.fromFile("someFile.txt").getLines().map(x => 1).sum
```

En Ruby también se realiza de forma breve, pero no tan elegante, ya que necesita una variable contador que va incrementando en cada vez que cuenta una línea. En Scala, una posible forma de hacerlo es usando `map`, una función que a cada línea del fichero le hace corresponder un `1`. Finalmente los suma todos llamando a `sum`.

Además, Scala soporta composición mixta a través de los traits. Los traits son parecidos a las clases abstractas con implementación parcial. Por ejemplo, podríamos crear un nuevo tipo de colección que permitiera acceder al contenido del fichero como un iterable, mezclando el trait `Iterable` de Scala:

```
class FileAsIterable {
  def iterator = scala.io.Source.fromFile("someFile.txt").getLines()
}
```

Ahora si lo mezclamos con el trait `Iterable` de Scala, al crear un objeto de esa clase, éste será un `Iterable`, teniendo acceso a los métodos de `Iterable`:

```
val newIterator = new FileAsIterable with Iterable[String]
newIterator.foreach { line => println(line) }
```

donde el método `foreach` al que llama, es de `Iterable`.

SCALA Y LA CONCURRENCIA

Uno de los grandes problemas de la concurrencia es que si no se coordina bien el acceso a los recursos puede haber cambios inesperados e indeseados en los mismos, por acción de alguna de las hebras.

Scala ayuda en esto con la inmutabilidad, de hecho, por defecto lo hace todo inmutable. Aunque en Scala se puede usar cualquier mecanismo de Java, Scala incorpora también sus propias herramientas específicas para concurrencia. Algunas de ellas son: Wampler & Payne^[38]

3.0.3 FUTURES

La API `scala.concurrent.Future` simplifica la concurrencia en código. Los Futures empiezan a correr concurrentemente cuando son creados, aunque lo hacen de forma asíncrona. Se puede hacer que las tareas sean independientes y sin bloqueo o por el contrario, bloquear, y además la API ofrece muchas funcionalidades para manejar los resultados (que pueden ser un Future), como callbacks que pueden ser invocados cuando el resultado esté listo. Veamos un ejemplo simple en el que se lanzan concurrentemente 5 tareas:

```
import scala.concurrent.Future
import scala.concurrent.ExecutionContext.Implicits.global

def sleep(millis: Long) = {
  Thread.sleep(millis)
}

// Busy work ;)

def doWork(index: Int) = {
  sleep((math.random * 1000).toLong)
  index
}
```

```

(1 to 5) foreach { index =>
  val future = Future {
    doWork(index)
  }
  future onSuccess {
    case answer: Int => println(s"Success! returned: $answer")
  }
  future onFailure {
    case th: Throwable => println(s"FAILURE! returned: $th")
  }
}
sleep(1000) // Wait long enough for the "work" to finish.
println("Finito!")

```

Se usa un método `SLEEP` para simular la ocupación por un tiempo. El método `DO WORK` llama a `sleep` con un número aleatorio de milisegundos. Se itera con `foreach` en un rango de enteros (1 a 5 inclusive) y se llama a `scala.concurrent.Future.apply`. En este caso, `Future.apply` recibe una función de trabajo a realizar (`doWork`), y devuelve un nuevo objeto `Future`, el cual ejecuta el cuerpo de `doWork(index)` en otra hebra, devolviendo el control inmediatamente al bucle. Finalmente se usan `onSuccess` (si la tarea se completa correctamente) y `onFailure` (si falla) para registrar los callbacks.

3.0.4 MODELO DE ACTORES

Una regla de la concurrencia es: si puedes, no compartas. Los actores son entidades software independientes que no comparten unos con otros información mutable que se pueda alterar. En su lugar se comunican mediante mensajes, eliminando la necesidad de sincronizar el acceso a datos, estados e información mutable. De esta forma es más fácil crear aplicaciones concurrentes robustas. Cada actor cambia su estado según lo necesite, pero sólo si tiene acceso exclusivo a ese estado y sus invocaciones se garantizan seguras.

SCALA Y BIG DATA

Las funciones `map`, `flatMap`, `filter`, `fold`, `reduce`...etc siempre han sido funciones para trabajar con datos, independientemente de que estos fueran grandes o pequeños. Es por esto que una vez que se entiende Scala y sus colecciones, resulta fácil enganchar una API de Big data basada en Scala, sin embargo, sabiendo Java, enganchar con MapReduce Java API resulta más complicado por ser más difícil de usar y estar a más bajo nivel.

Pero la principal ventaja de Scala en Big data frente a otros lenguajes no es la curva de aprendizaje, sino la programación funcional. Scala permite escribir lo mismo (o más), con menos código que otros lenguajes. El ejemplo simple de contar el número de palabras, sacado de Wampler & Payne^[38] bastará para evidenciar a simple vista la ventaja de las APIs Big data basadas en Scala frente a las basadas en Java.

Esto es sólo parte de la versión Hadoop. El original se compone de unas 60 líneas de código, sin imports ni comentarios.

```
// src/main/java/progscala2/bigdata/HadoopWordCount.javaX
...
class WordCountMapper extends MapReduceBase
    implements Mapper<IntWritable, Text, Text, IntWritable> {

    static final IntWritable one = new IntWritable(1);
    static final Text word = new Text();

    @Override public void map(IntWritable key, Text valueDocContents,
        OutputCollector<Text, IntWritable> output, Reporter reporter) {
        String[] tokens = valueDocContents.toString.split("\\s+");
        for (String wordString: tokens) {
            if (wordString.length > 0) {
                word.set(wordString.toLowerCase());
                output.collect(word, one);
            }
        }
    }
}
```

```

    }
}

class WordCountReduce extends MapReduceBase
    implements Reducer<Text, IntWritable, Text, IntWritable> {

    public void reduce(Text keyWord, java.util.Iterator<IntWritable> counts,
        OutputCollector<Text, IntWritable> output, Reporter reporter) {
        int totalCount = 0;
        while (counts.hasNext) {
            totalCount += counts.next.get;
        }
    }
}

```

Ahora una versión Scalding, basado en Scala. El código original tiene 12 líneas de código, contando el import:

```

// src/main/scala/progscala2/bigdata/WordCountScalding.scalaX
import com.twitter.scalding._

class WordCount(args : Args) extends Job(args) {

    TextLine(args("input"))
        .read
        .flatMap('line -> 'word) {
            line: String => line.trim.toLowerCase.split("\\s+")
        }
        .groupBy('word){ group => group.size('count) }
        .write(Tsv(args("output")))
}

```

“How well we communicate is determined not by how well we say things, but how well we are understood.”


Andrew Grove

4

Planificación, análisis y diseño

Planificación

A continuación se expone mediante un **diagrama de Gantt** como se ha distribuido el tiempo durante estos 5 meses para cada tarea de este proyecto, a partir de mediados de Julio hasta la segunda semana de Diciembre.



Análisis de requisitos

En esta sección se muestra la especificación de requisitos para el proyecto de manera formal, a través de plantillas que muestran información relevante del requisito, como la descripción, su prioridad, estado o riesgo. Al ser demasiados, se exponen solo los más importantes.

REQUISITOS FUNCIONALES

Identificador: RF-01		
Necesidad: Alta	Autor: Cristina Heredia	
Descripción: El sistema incluirá un método de parseado de texto, al que el usuario especificará una cadena de texto y cual de las tres tareas desea realizar(tokenizado, etiquetado, lematización) mediante parámetros booleanos. Devuelve el resultado de aplicarle al texto especificado la acción solicitada. Si no se especifica opción, devuelve el texto tal como lo especificó el usuario.		
Prioridad: Alta	Riesgo: Medio	
Dependencias: RF-02, RF-03, RF-07		Estado: Hecho

Identificador: RF-02	
Necesidad: Alta	Autor: Cristina Heredia
Descripción: El sistema incluirá un método de procedimiento de tokenización de texto, que separará el texto en sus unidades mínimas; los tokens. Si el texto contiene emoticonos, los cambia por el sentimiento que tengan asociado. Recibe como parámetro una cadena de texto especificada por el usuario. Devuelve una lista de listas de tokens, donde cada lista de tokens se corresponde con una frase del texto del usuario.	
Prioridad: Alta	Riesgo: Medio
Dependencias:	Estado: Hecho

Identificador: RF-03		
Necesidad: Alta	Autor: Cristina Heredia	
Descripción: El sistema incluirá un método de etiquetado morfosintáctico de texto (POS Tagger), que etiquetará cada palabra(token) con su categoría morfosintáctica según el léxico, una morfología y un contexto que recibirá como parámetro. También recibe como parámetro una lista con los tokens del texto introducido por el usuario, por lo tanto requiere de una tokenización previamente. Devuelve una lista de pares (token,etiqueta).		
Prioridad: Alta	Riesgo: Medio	
Dependencias: RF-02,RF-04,RF-05, RF-06	Estado: Hecho	

Identificador: RF-04		
Necesidad: Alta	Autor: Cristina Heredia	
Descripción: El sistema incluirá un método de aplicación de un contexto a una lista de tokens ya etiquetados morfosintácticamente, para mejorar el etiquetado de los mismos. Como resultado devuelve una lista con los tokens y sus nuevas etiquetas, en un par (token,tag).		
Prioridad: Alta	Riesgo: Medio	
Dependencias: RF-02, RF-05	Estado: Hecho	

Identificador: RF-05		
Necesidad: Alta	Autor: Cristina Heredia	
Descripción: El sistema incluirá un método de creación de un diccionario de léxico, a partir de la lectura y manipulación de un fichero de 85877 líneas de reglas léxicas. Éste será usado en el POS tagger para realizar un etiquetado inicial.		
Prioridad: Alta	Riesgo: Medio	
Dependencias:	Estado: Hecho	

Identificador: RF-o6		
Necesidad: Alta	Autor: Cristina Heredia	
Descripción: El sistema incluirá un proceso de aplicación de reglas morfológicas a un token dado con una etiqueta dada, que se reciben como parámetros. Ésto sirve de nuevo para mejorar el etiquetado, esta vez teniendo en cuenta la morfología.		
Prioridad: Alta	Riesgo: Medio	
Dependencias: RF-o2, RF-o5	Estado: Hecho	

Identificador: RF-07		
Necesidad: Alta	Autor: Cristina Heredia	
Descripción: El sistema incluirá un proceso de lematización que obtendrá la forma base de la palabra, aplicando un diccionario y varios algoritmos. Requiere de un etiquetado previo de las palabras, por lo que recibe como argumento una lista de (palabra,etiqueta) y devuelve una lista de (palabra,etiqueta,lema).		
Prioridad: Alta	Riesgo: Medio	
Dependencias: RF-03	Estado: Hecho	

REQUISITOS NO FUNCIONALES

Identificador: RNF-01		
Necesidad: Alta	Autor: Cristina Heredia	
Descripción: El método de Pos etiquetado a implementar para el español debe tener un acierto medio mayor o igual a 0.80.		
Prioridad: Alta	Riesgo: Medio	
Dependencias:	Estado: Hecho	

Identificador: RNF-02		
Necesidad: Alta	Autor: Cristina Heredia	
Descripción: El método de lematización para español a implementar debe tener un acierto medio mayor o igual a 0.90.		
Prioridad: Alta	Riesgo: Medio	
Dependencias:	Estado: Hecho	

Identificador: RNF-03		
Necesidad: Alta	Autor: Cristina Heredia	
Descripción: El sistema debe implementarse usando siempre inmutabilidad.		
Prioridad: Media	Riesgo: Medio	
Dependencias:	Estado: Propuesto	

Diseño

En este apartado se explica lo relativo al diseño de clases y métodos realizado para este trabajo junto con la metodología que se ha seguido para su implementación.

METODOLOGÍA USADA

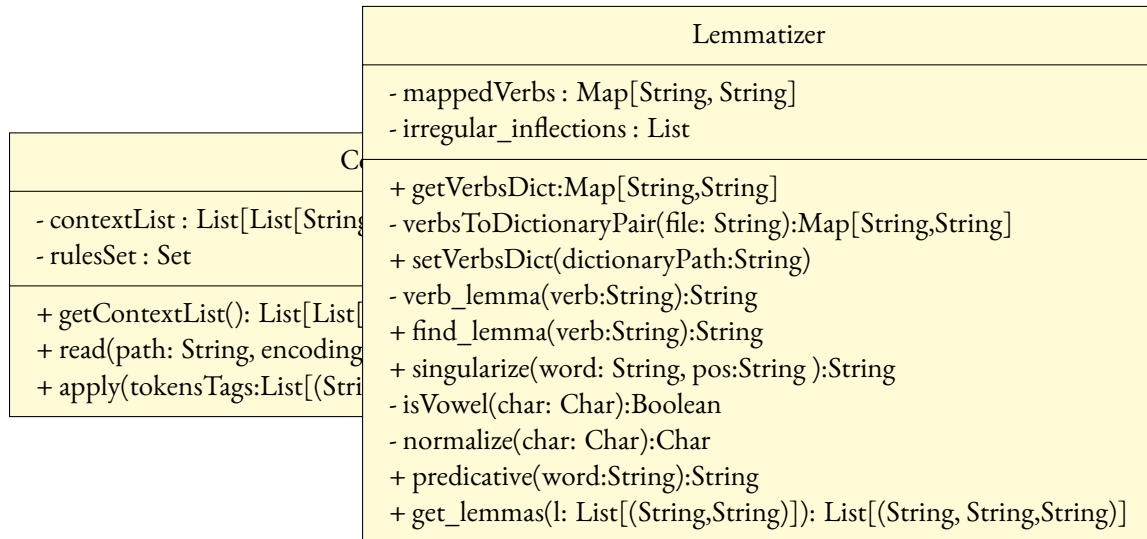
En este trabajo se ha tratado de seguir la metodología de **desarrollo dirigido a documentos** (TDD), un conocido procedimiento de desarrollo cuya idea es hacer las pruebas inicialmente, de forma previa a la implementación. En concreto, se hacen test unitarios para testear las funcionalidades más importantes del trabajo.

El procedimiento seguido es el siguiente: en primer lugar se elige una funcionalidad a implementar, por ejemplo, el tokenizado de una cadena de texto. Luego se escribe una prueba para testear si dicha funcionalidad es correcta o no, prueba que inicialmente no pasará al no estar implementada aún dicha funcionalidad:

```
//testing find tokens method
test("find tokens test") {
    assert(tokenizer.find_tokens(string1) == List(List("Los", "gatos", "negros",
    ↪ "son", "bonitos", ".")))
    assert(tokenizer.find_tokens(string2) == List(List("Nadie", "podrá",
    ↪ "vivir", "eternamente")))
    //....
}
```

El siguiente paso es implementar el método `find_tokens`. Una vez implementado, se vuelve a ejecutar el test, y si lo pasa se refactoriza y se vuelve a ejecutar el test. Después se toma otra funcionalidad y se repite el proceso.

DISEÑO DE CLASES



5

Material empleado

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Morbi commodo, ipsum sed pharetra gravida, orci magna rhoncus neque, id pulvinar odio lorem non turpis. Nullam sit amet enim. Suspendisse id velit vitae ligula volutpat condimentum. Aliquam erat volutpat. Sed quis velit. Nulla facilisi. Nulla libero. Vivamus pharetra posuere sapien. Nam consectetur. Sed aliquam, nunc eget euismod ullamcorper, lectus nunc ullamcorper orci, fermentum bibendum enim nibh eget ipsum. Donec porttitor ligula eu dolor. Maecenas vitae nulla consequat libero cursus venenatis. Nam magna enim, accumsan eu, blandit sed, blandit a, eros.

Quisque facilisis erat a dui. Nam malesuada ornare dolor. Cras gravida, diam sit amet rhoncus ornare, erat elit consectetur erat, id egestas pede nibh eget odio. Proin tincidunt, velit vel porta elementum, magna diam molestie sapien, non aliquet massa pede eu diam. Aliquam iaculis. Fusce et ipsum et nulla tristique facilisis. Donec eget sem sit amet ligula viverra gravida. Etiam vehicula urna vel turpis. Suspendisse sagittis ante a urna. Morbi a est quis orci consequat rutrum. Nullam egestas feugiat felis. Integer adipiscing semper ligula. Nunc molestie, nisl sit amet cursus convallis, sapien lectus pretium metus, vitae pretium enim wisi id lectus. Donec vestibulum. Etiam vel nibh. Nulla

facilisi. Mauris pharetra. Donec augue. Fusce ultrices, neque id dignissim ultrices, tellus mauris dictum elit, vel lacinia enim metus eu nunc.

Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Vestibulum tortor quam, feugiat vitae, ultricies eget, tempor sit amet, ante. Donec eu libero sit amet quam egestas semper. Aenean ultricies mi vitae est. Mauris placerat eleifend leo. Quisque sit amet est et sapien ullamcorper pharetra. Vestibulum erat wisi, condimentum sed, commodo vitae, ornare sit amet, wisi. Aenean fermentum, elit eget tincidunt condimentum, eros ipsum rutrum orci, sagittis tempus lacus enim ac dui. Donec non enim in turpis pulvinar facilisis. Ut felis.

Cras sed ante. Phasellus in massa. Curabitur dolor eros, gravida et, hendrerit ac, cursus non, massa. Aliquam lorem. In hac habitasse platea dictumst. Cras eu mauris. Quisque lacus. Donec ipsum. Nullam vitae sem at nunc pharetra ultricies. Vivamus elit eros, ullamcorper a, adipiscing sit amet, porttitor ut, nibh. Maecenas adipiscing mollis massa. Nunc ut dui eget nulla venenatis aliquet. Sed luctus posuere justo. Cras vehicula varius turpis. Vivamus eros metus, tristique sit amet, molestie dignissim, malesuada et, urna.

Cras dictum. Maecenas ut turpis. In vitae erat ac orci dignissim eleifend. Nunc quis justo. Sed vel ipsum in purus tincidunt pharetra. Sed pulvinar, felis id consectetur malesuada, enim nisl mattis elit, a facilisis tortor nibh quis leo. Sed augue lacus, pretium vitae, molestie eget, rhoncus quis, elit. Donec in augue. Fusce orci wisi, ornare id, mollis vel, lacinia vel, massa.

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Morbi commodo, ipsum sed pharetra gravida, orci magna rhoncus neque, id pulvinar odio lorem non turpis. Nullam sit amet enim. Suspendisse id velit vitae ligula volutpat condimentum. Aliquam erat volutpat. Sed quis velit. Nulla facilisi. Nulla libero. Vivamus pharetra posuere sapien. Nam consectetur. Sed aliquam, nunc eget euismod ullamcorper, lectus nunc ullamcorper orci, fermentum bibendum enim nibh eget ipsum. Donec porttitor ligula eu dolor. Maecenas vitae nulla consequat libero cursus venenatis. Nam magna enim, accumsan eu, blandit sed, blandit a, eros.

Quisque facilisis erat a dui. Nam malesuada ornare dolor. Cras gravida, diam sit amet rhoncus ornare, erat elit consectetur erat, id egestas pede nibh eget odio. Proin tincidunt, velit vel porta elementum, magna diam molestie sapien, non aliquet massa pede eu diam. Aliquam iaculis. Fusce et ipsum et nulla tristique facilisis. Donec eget sem sit amet ligula viverra gravida. Etiam vehicula urna

vel turpis. Suspendisse sagittis ante a urna. Morbi a est quis orci consequat rutrum. Nullam egestas feugiat felis. Integer adipiscing semper ligula. Nunc molestie, nisl sit amet cursus convallis, sapien lectus pretium metus, vitae pretium enim wisi id lectus. Donec vestibulum. Etiam vel nibh. Nulla facilisi. Mauris pharetra. Donec augue. Fusce ultrices, neque id dignissim ultrices, tellus mauris dictum elit, vel lacinia enim metus eu nunc.

6

Implementación y pruebas

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Morbi commodo, ipsum sed pharetra gravida, orci magna rhoncus neque, id pulvinar odio lorem non turpis. Nullam sit amet enim. Suspendisse id velit vitae ligula volutpat condimentum. Aliquam erat volutpat. Sed quis velit. Nulla facilisi. Nulla libero. Vivamus pharetra posuere sapien. Nam consectetur. Sed aliquam, nunc eget euismod ullamcorper, lectus nunc ullamcorper orci, fermentum bibendum enim nibh eget ipsum. Donec porttitor ligula eu dolor. Maecenas vitae nulla consequat libero cursus venenatis. Nam magna enim, accumsan eu, blandit sed, blandit a, eros.

Quisque facilisis erat a dui. Nam malesuada ornare dolor. Cras gravida, diam sit amet rhoncus ornare, erat elit consectetur erat, id egestas pede nibh eget odio. Proin tincidunt, velit vel porta elementum, magna diam molestie sapien, non aliquet massa pede eu diam. Aliquam iaculis. Fusce et ipsum et nulla tristique facilisis. Donec eget sem sit amet ligula viverra gravida. Etiam vehicula urna vel turpis. Suspendisse sagittis ante a urna. Morbi a est quis orci consequat rutrum. Nullam egestas feugiat felis. Integer adipiscing semper ligula. Nunc molestie, nisl sit amet cursus convallis, sapien lectus pretium metus, vitae pretium enim wisi id lectus. Donec vestibulum. Etiam vel nibh. Nulla

facilisi. Mauris pharetra. Donec augue. Fusce ultrices, neque id dignissim ultrices, tellus mauris dictum elit, vel lacinia enim metus eu nunc.

Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Vestibulum tortor quam, feugiat vitae, ultricies eget, tempor sit amet, ante. Donec eu libero sit amet quam egestas semper. Aenean ultricies mi vitae est. Mauris placerat eleifend leo. Quisque sit amet est et sapien ullamcorper pharetra. Vestibulum erat wisi, condimentum sed, commodo vitae, ornare sit amet, wisi. Aenean fermentum, elit eget tincidunt condimentum, eros ipsum rutrum orci, sagittis tempus lacus enim ac dui. Donec non enim in turpis pulvinar facilisis. Ut felis.

Cras sed ante. Phasellus in massa. Curabitur dolor eros, gravida et, hendrerit ac, cursus non, massa. Aliquam lorem. In hac habitasse platea dictumst. Cras eu mauris. Quisque lacus. Donec ipsum. Nullam vitae sem at nunc pharetra ultricies. Vivamus elit eros, ullamcorper a, adipiscing sit amet, porttitor ut, nibh. Maecenas adipiscing mollis massa. Nunc ut dui eget nulla venenatis aliquet. Sed luctus posuere justo. Cras vehicula varius turpis. Vivamus eros metus, tristique sit amet, molestie dignissim, malesuada et, urna.

Cras dictum. Maecenas ut turpis. In vitae erat ac orci dignissim eleifend. Nunc quis justo. Sed vel ipsum in purus tincidunt pharetra. Sed pulvinar, felis id consectetur malesuada, enim nisl mattis elit, a facilisis tortor nibh quis leo. Sed augue lacus, pretium vitae, molestie eget, rhoncus quis, elit. Donec in augue. Fusce orci wisi, ornare id, mollis vel, lacinia vel, massa.

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Morbi commodo, ipsum sed pharetra gravida, orci magna rhoncus neque, id pulvinar odio lorem non turpis. Nullam sit amet enim. Suspendisse id velit vitae ligula volutpat condimentum. Aliquam erat volutpat. Sed quis velit. Nulla facilisi. Nulla libero. Vivamus pharetra posuere sapien. Nam consectetur. Sed aliquam, nunc eget euismod ullamcorper, lectus nunc ullamcorper orci, fermentum bibendum enim nibh eget ipsum. Donec porttitor ligula eu dolor. Maecenas vitae nulla consequat libero cursus venenatis. Nam magna enim, accumsan eu, blandit sed, blandit a, eros.

Quisque facilisis erat a dui. Nam malesuada ornare dolor. Cras gravida, diam sit amet rhoncus ornare, erat elit consectetur erat, id egestas pede nibh eget odio. Proin tincidunt, velit vel porta elementum, magna diam molestie sapien, non aliquet massa pede eu diam. Aliquam iaculis. Fusce et ipsum et nulla tristique facilisis. Donec eget sem sit amet ligula viverra gravida. Etiam vehicula urna

vel turpis. Suspendisse sagittis ante a urna. Morbi a est quis orci consequat rutrum. Nullam egestas feugiat felis. Integer adipiscing semper ligula. Nunc molestie, nisl sit amet cursus convallis, sapien lectus pretium metus, vitae pretium enim wisi id lectus. Donec vestibulum. Etiam vel nibh. Nulla facilisi. Mauris pharetra. Donec augue. Fusce ultrices, neque id dignissim ultrices, tellus mauris dictum elit, vel lacinia enim metus eu nunc.

7

Conclusiones y vías futuras

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Morbi commodo, ipsum sed pharetra gravida, orci magna rhoncus neque, id pulvinar odio lorem non turpis. Nullam sit amet enim. Suspendisse id velit vitae ligula volutpat condimentum. Aliquam erat volutpat. Sed quis velit. Nulla facilisi. Nulla libero. Vivamus pharetra posuere sapien. Nam consectetur. Sed aliquam, nunc eget euismod ullamcorper, lectus nunc ullamcorper orci, fermentum bibendum enim nibh eget ipsum. Donec porttitor ligula eu dolor. Maecenas vitae nulla consequat libero cursus venenatis. Nam magna enim, accumsan eu, blandit sed, blandit a, eros.

Quisque facilisis erat a dui. Nam malesuada ornare dolor. Cras gravida, diam sit amet rhoncus ornare, erat elit consectetur erat, id egestas pede nibh eget odio. Proin tincidunt, velit vel porta elementum, magna diam molestie sapien, non aliquet massa pede eu diam. Aliquam iaculis. Fusce et ipsum et nulla tristique facilisis. Donec eget sem sit amet ligula viverra gravida. Etiam vehicula urna vel turpis. Suspendisse sagittis ante a urna. Morbi a est quis orci consequat rutrum. Nullam egestas feugiat felis. Integer adipiscing semper ligula. Nunc molestie, nisl sit amet cursus convallis, sapien lectus pretium metus, vitae pretium enim wisi id lectus. Donec vestibulum. Etiam vel nibh. Nulla

facilisi. Mauris pharetra. Donec augue. Fusce ultrices, neque id dignissim ultrices, tellus mauris dictum elit, vel lacinia enim metus eu nunc.

Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Vestibulum tortor quam, feugiat vitae, ultricies eget, tempor sit amet, ante. Donec eu libero sit amet quam egestas semper. Aenean ultricies mi vitae est. Mauris placerat eleifend leo. Quisque sit amet est et sapien ullamcorper pharetra. Vestibulum erat wisi, condimentum sed, commodo vitae, ornare sit amet, wisi. Aenean fermentum, elit eget tincidunt condimentum, eros ipsum rutrum orci, sagittis tempus lacus enim ac dui. Donec non enim in turpis pulvinar facilisis. Ut felis.

Cras sed ante. Phasellus in massa. Curabitur dolor eros, gravida et, hendrerit ac, cursus non, massa. Aliquam lorem. In hac habitasse platea dictumst. Cras eu mauris. Quisque lacus. Donec ipsum. Nullam vitae sem at nunc pharetra ultricies. Vivamus elit eros, ullamcorper a, adipiscing sit amet, porttitor ut, nibh. Maecenas adipiscing mollis massa. Nunc ut dui eget nulla venenatis aliquet. Sed luctus posuere justo. Cras vehicula varius turpis. Vivamus eros metus, tristique sit amet, molestie dignissim, malesuada et, urna.

Cras dictum. Maecenas ut turpis. In vitae erat ac orci dignissim eleifend. Nunc quis justo. Sed vel ipsum in purus tincidunt pharetra. Sed pulvinar, felis id consectetur malesuada, enim nisl mattis elit, a facilisis tortor nibh quis leo. Sed augue lacus, pretium vitae, molestie eget, rhoncus quis, elit. Donec in augue. Fusce orci wisi, ornare id, mollis vel, lacinia vel, massa.

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Morbi commodo, ipsum sed pharetra gravida, orci magna rhoncus neque, id pulvinar odio lorem non turpis. Nullam sit amet enim. Suspendisse id velit vitae ligula volutpat condimentum. Aliquam erat volutpat. Sed quis velit. Nulla facilisi. Nulla libero. Vivamus pharetra posuere sapien. Nam consectetur. Sed aliquam, nunc eget euismod ullamcorper, lectus nunc ullamcorper orci, fermentum bibendum enim nibh eget ipsum. Donec porttitor ligula eu dolor. Maecenas vitae nulla consequat libero cursus venenatis. Nam magna enim, accumsan eu, blandit sed, blandit a, eros.

Quisque facilisis erat a dui. Nam malesuada ornare dolor. Cras gravida, diam sit amet rhoncus ornare, erat elit consectetur erat, id egestas pede nibh eget odio. Proin tincidunt, velit vel porta elementum, magna diam molestie sapien, non aliquet massa pede eu diam. Aliquam iaculis. Fusce et ipsum et nulla tristique facilisis. Donec eget sem sit amet ligula viverra gravida. Etiam vehicula urna

vel turpis. Suspendisse sagittis ante a urna. Morbi a est quis orci consequat rutrum. Nullam egestas feugiat felis. Integer adipiscing semper ligula. Nunc molestie, nisl sit amet cursus convallis, sapien lectus pretium metus, vitae pretium enim wisi id lectus. Donec vestibulum. Etiam vel nibh. Nulla facilisi. Mauris pharetra. Donec augue. Fusce ultrices, neque id dignissim ultrices, tellus mauris dictum elit, vel lacinia enim metus eu nunc.



Some extra stuff

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Morbi commodo, ipsum sed pharetra gravida, orci magna rhoncus neque, id pulvinar odio lorem non turpis. Nullam sit amet enim. Suspendisse id velit vitae ligula volutpat condimentum. Aliquam erat volutpat. Sed quis velit. Nulla facilisi. Nulla libero. Vivamus pharetra posuere sapien. Nam consectetur. Sed aliquam, nunc eget euismod ullamcorper, lectus nunc ullamcorper orci, fermentum bibendum enim nibh eget ipsum. Donec porttitor ligula eu dolor. Maecenas vitae nulla consequat libero cursus venenatis. Nam magna enim, accumsan eu, blandit sed, blandit a, eros.

Quisque facilisis erat a dui. Nam malesuada ornare dolor. Cras gravida, diam sit amet rhoncus ornare, erat elit consectetur erat, id egestas pede nibh eget odio. Proin tincidunt, velit vel porta elementum, magna diam molestie sapien, non aliquet massa pede eu diam. Aliquam iaculis. Fusce et ipsum et nulla tristique facilisis. Donec eget sem sit amet ligula viverra gravida. Etiam vehicula urna vel turpis. Suspendisse sagittis ante a urna. Morbi a est quis orci consequat rutrum. Nullam egestas feugiat felis. Integer adipiscing semper ligula. Nunc molestie, nisl sit amet cursus convallis, sapien lectus pretium metus, vitae pretium enim wisi id lectus. Donec vestibulum. Etiam vel nibh. Nulla

facilisi. Mauris pharetra. Donec augue. Fusce ultrices, neque id dignissim ultrices, tellus mauris dictum elit, vel lacinia enim metus eu nunc.

Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Vestibulum tortor quam, feugiat vitae, ultricies eget, tempor sit amet, ante. Donec eu libero sit amet quam egestas semper. Aenean ultricies mi vitae est. Mauris placerat eleifend leo. Quisque sit amet est et sapien ullamcorper pharetra. Vestibulum erat wisi, condimentum sed, commodo vitae, ornare sit amet, wisi. Aenean fermentum, elit eget tincidunt condimentum, eros ipsum rutrum orci, sagittis tempus lacus enim ac dui. Donec non enim in turpis pulvinar facilisis. Ut felis.

Cras sed ante. Phasellus in massa. Curabitur dolor eros, gravida et, hendrerit ac, cursus non, massa. Aliquam lorem. In hac habitasse platea dictumst. Cras eu mauris. Quisque lacus. Donec ipsum. Nullam vitae sem at nunc pharetra ultricies. Vivamus elit eros, ullamcorper a, adipiscing sit amet, porttitor ut, nibh. Maecenas adipiscing mollis massa. Nunc ut dui eget nulla venenatis aliquet. Sed luctus posuere justo. Cras vehicula varius turpis. Vivamus eros metus, tristique sit amet, molestie dignissim, malesuada et, urna.

Cras dictum. Maecenas ut turpis. In vitae erat ac orci dignissim eleifend. Nunc quis justo. Sed vel ipsum in purus tincidunt pharetra. Sed pulvinar, felis id consectetur malesuada, enim nisl mattis elit, a facilisis tortor nibh quis leo. Sed augue lacus, pretium vitae, molestie eget, rhoncus quis, elit. Donec in augue. Fusce orci wisi, ornare id, mollis vel, lacinia vel, massa.

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Morbi commodo, ipsum sed pharetra gravida, orci magna rhoncus neque, id pulvinar odio lorem non turpis. Nullam sit amet enim. Suspendisse id velit vitae ligula volutpat condimentum. Aliquam erat volutpat. Sed quis velit. Nulla facilisi. Nulla libero. Vivamus pharetra posuere sapien. Nam consectetur. Sed aliquam, nunc eget euismod ullamcorper, lectus nunc ullamcorper orci, fermentum bibendum enim nibh eget ipsum. Donec porttitor ligula eu dolor. Maecenas vitae nulla consequat libero cursus venenatis. Nam magna enim, accumsan eu, blandit sed, blandit a, eros.

Quisque facilisis erat a dui. Nam malesuada ornare dolor. Cras gravida, diam sit amet rhoncus ornare, erat elit consectetur erat, id egestas pede nibh eget odio. Proin tincidunt, velit vel porta elementum, magna diam molestie sapien, non aliquet massa pede eu diam. Aliquam iaculis. Fusce et ipsum et nulla tristique facilisis. Donec eget sem sit amet ligula viverra gravida. Etiam vehicula urna

vel turpis. Suspendisse sagittis ante a urna. Morbi a est quis orci consequat rutrum. Nullam egestas feugiat felis. Integer adipiscing semper ligula. Nunc molestie, nisl sit amet cursus convallis, sapien lectus pretium metus, vitae pretium enim wisi id lectus. Donec vestibulum. Etiam vel nibh. Nulla facilisi. Mauris pharetra. Donec augue. Fusce ultrices, neque id dignissim ultrices, tellus mauris dictum elit, vel lacinia enim metus eu nunc.

References

- [1] Baldridge, J. (2005). The opennlp project. URL: <http://opennlp.apache.org/index.html>, (accessed 2 February 2012).
- [2] Berger, A. L., Pietra, V. J. D., & Pietra, S. A. D. (1996). A maximum entropy approach to natural language processing. *Computational linguistics*, 22(1), 39–71.
- [3] Bird, S. (2006). Nltk: the natural language toolkit. In *Proceedings of the COLING/ACL on Interactive presentation sessions* (pp. 69–72).: Association for Computational Linguistics.
- [4] Bird, S., Klein, E., & Loper, E. (2009). *Natural language processing with Python*. ” O’Reilly Media, Inc.”.
- [5] Bollen, J., Mao, H., & Pepe, A. (2011). Modeling public mood and emotion: Twitter sentiment and socio-economic phenomena. *ICWSM*, 11, 450–453.
- [6] Chang, P.-C., Galley, M., & Manning, C. D. (2008). Optimizing chinese word segmentation for machine translation performance. In *Proceedings of the third workshop on statistical machine translation* (pp. 224–232).: Association for Computational Linguistics.
- [7] Culotta, A. & Sorensen, J. (2004). Dependency tree kernels for relation extraction. In *Proceedings of the 42nd Annual Meeting on Association for Computational Linguistics* (pp. 423).: Association for Computational Linguistics.
- [8] Ding, X., Liu, B., & Yu, P. S. (2008). A holistic lexicon-based approach to opinion mining. In *Proceedings of the 2008 international conference on web search and data mining* (pp. 231–240).: ACM.
- [9] Elhadad, N., Gravano, L., Hsu, D., Balter, S., Reddy, V., & Waechter, H. (2014). Information extraction from social media for public health. In *KDD at Bloomberg Workshop, Data Frameworks Track (KDD 2014)*.
- [10] Etzioni, O., Fader, A., Christensen, J., Soderland, S., & Mausam, M. (2011). Open information extraction: The second generation. In *IJCAI*, volume 11 (pp. 3–10).

- [11] Giesbrecht, E. & Evert, S. (2009). Is part-of-speech tagging a solved task? an evaluation of pos taggers for the german web as corpus. In *Proceedings of the fifth Web as Corpus workshop* (pp. 27–35).
- [12] Giménez, J. & Marquez, L. (2004). Svmtool: A general pos tagger generator based on support vector machines. In *In Proceedings of the 4th International Conference on Language Resources and Evaluation*: Citeseer.
- [13] Gonçalves, P., Benevenuto, F., & Cha, M. (2013). Panas-t: A psychometric scale for measuring sentiments on twitter. *arXiv preprint arXiv:1308.1857*.
- [14] Hinton, G., Deng, L., Yu, D., Dahl, G. E., Mohamed, A.-r., Jaitly, N., Senior, A., Vanhoucke, V., Nguyen, P., Sainath, T. N., et al. (2012). Deep neural networks for acoustic modeling in speech recognition: The shared views of four research groups. *IEEE Signal Processing Magazine*, 29(6), 82–97.
- [15] Hirschberg, J. & Manning, C. D. (2015). Advances in natural language processing. *Science*, 349(6245), 261–266.
- [16] Hu, M. & Liu, B. (2004). Mining and summarizing customer reviews. In *Proceedings of the tenth ACM SIGKDD international conference on Knowledge discovery and data mining* (pp. 168–177): ACM.
- [17] Jiang, L., Yu, M., Zhou, M., Liu, X., & Zhao, T. (2011). Target-dependent twitter sentiment classification. In *Proceedings of the 49th Annual Meeting of the Association for Computational Linguistics: Human Language Technologies-Volume 1* (pp. 151–160): Association for Computational Linguistics.
- [18] Joachims, T. (1998). Text categorization with support vector machines: Learning with many relevant features. In *European conference on machine learning* (pp. 137–142): Springer.
- [19] Kiss, T. & Strunk, J. (2006). Unsupervised multilingual sentence boundary detection. *Computational Linguistics*, 32(4), 485–525.
- [20] Lewis, D. D. (1998). Naive (bayes) at forty: The independence assumption in information retrieval. In *European conference on machine learning* (pp. 4–15): Springer.
- [21] Liu, B. (2015). *Sentiment Analysis: Mining Opinions, Sentiments, and Emotions*. Cambridge University Press.

- [22] Luong, M.-T., Sutskever, I., Le, Q. V., Vinyals, O., & Zaremba, W. (2014). Addressing the rare word problem in neural machine translation. *arXiv preprint arXiv:1410.8206*.
- [23] Manning, C. D., Surdeanu, M., Bauer, J., Finkel, J. R., Bethard, S., & McClosky, D. (2014). The stanford corenlp natural language processing toolkit. In *ACL (System Demonstrations)* (pp. 55–60).
- [24] Marcus, M. P., Marcinkiewicz, M. A., & Santorini, B. (1993). Building a large annotated corpus of english: The penn treebank. *Computational linguistics*, 19(2), 313–330.
- [25] Màrquez, L., Villarejo, L., Martí, M., & Taulé, M. (2007). Semeval-2007 task 09: Multilevel semantic annotation of catalan and spanish. In *Proceedings of the 4th International Workshop on Semantic Evaluations* (pp. 42–47).: Association for Computational Linguistics.
- [26] Nadkarni, P. M., Ohno-Machado, L., & Chapman, W. W. (2011). Natural language processing: an introduction. *Journal of the American Medical Informatics Association*, 18(5), 544–551.
- [27] Niu, F., Zhang, C., Ré, C., & Shavlik, J. W. (2012). Deepdive: Web-scale knowledge-base construction using statistical learning and inference. *VLDS*, 12, 25–28.
- [28] Nivre, J., Hall, J., & Nilsson, J. (2006). Maltparser: A data-driven parser-generator for dependency parsing. In *Proceedings of LREC*, volume 6 (pp. 2216–2219).
- [29] Padró, L. & Stanilovsky, E. (2012). Freeling 3.0: Towards wider multilinguality. In *LREC2012*.
- [30] Pang, B., Lee, L., & Vaithyanathan, S. (2002). Thumbs up?: sentiment classification using machine learning techniques. In *Proceedings of the ACL-02 conference on Empirical methods in natural language processing-Volume 10* (pp. 79–86).: Association for Computational Linguistics.
- [31] Ribeiro, F. N., Araújo, M., Gonçalves, P., Gonçalves, M. A., & Benevenuto, F. (2016). Sentibench-a benchmark comparison of state-of-the-practice sentiment analysis methods. *EPJ Data Science*, 5(1), 1–29.
- [32] Riloff, E. & Wiebe, J. (2003). Learning extraction patterns for subjective expressions. In *Proceedings of the 2003 conference on Empirical methods in natural language processing* (pp. 105–112).: Association for Computational Linguistics.

- [33] Rodrigues, M. J. F. & da Silva Teixeira, A. J. (2015). *Advanced Applications of Natural Language Processing for Performing Information Extraction (SpringerBriefs in Electrical and Computer Engineering)*. Springer.
- [34] Schmid, H. (1995). Treetagger| a language independent part-of-speech tagger. *Institut für Maschinelle Sprachverarbeitung, Universität Stuttgart*, 43, 28.
- [35] Smedt, T. D. & Daelemans, W. (2012). Pattern for python. *Journal of Machine Learning Research*, 13(Jun), 2063–2067.
- [36] Tausczik, Y. R. & Pennebaker, J. W. (2010). The psychological meaning of words: Liwc and computerized text analysis methods. *Journal of language and social psychology*, 29(1), 24–54.
- [37] Turney, P. D. (2002). Thumbs up or thumbs down?: semantic orientation applied to unsupervised classification of reviews. In *Proceedings of the 40th annual meeting on association for computational linguistics* (pp. 417–424).: Association for Computational Linguistics.
- [38] Wampler, D. & Payne, A. (2014). *Programming Scala: Scalability = Functional Programming + Objects*. O'Reilly Media.
- [39] Wang, H. (2015). *Sentiment-aligned Topic Models for Product Aspect Rating Prediction*. PhD thesis, Applied Sciences: School of Computing Science.
- [40] Westerski, A. (2007). Sentiment analysis: Introduction and the state of the art overview. *Universidad Politecnica de Madrid, Spain*, (pp. 211–218).
- [41] Whissell, C. (1989). The dictionary of affect in language. *Emotion: Theory, research, and experience*, 4(113-131), 94.
- [42] Wiebe, J., Wilson, T., & Cardie, C. (2005). Annotating expressions of opinions and emotions in language. *Language resources and evaluation*, 39(2-3), 165–210.
- [43] Wong, D. F., Chao, L. S., & Zeng, X. (2014). isentenizer-: Multilingual sentence boundary detection model. *The Scientific World Journal*, 2014.
- [44] Young, S., Gašić, M., Thomson, B., & Williams, J. D. (2013). Pomdp-based statistical spoken dialog systems: A review. *Proceedings of the IEEE*, 101(5), 1160–1179.
- [45] Yu, H. & Hatzivassiloglou, V. (2003). Towards answering opinion questions: Separating facts from opinions and identifying the polarity of opinion sentences. In *Proceedings of the 2003*

conference on Empirical methods in natural language processing (pp. 129–136).: Association for Computational Linguistics.



THIS THESIS WAS TYPESET using \LaTeX , originally developed by Leslie Lamport and based on Donald Knuth's \TeX .

The body text is set in 11 point Egenolff-Berner Garamond, a revival of Claude Garamont's humanist typeface. The above illustration, *Science Experiment 02*, was created by Ben Schlitter and released under [CC BY-NC-ND 3.0](#). A template that can be used to format a PhD dissertation with this look & feel has been released under the permissive AGPL license, and can be found online at github.com/suchow/Dissertate or from its lead author, Jordan Suchow, at suchow@post.harvard.edu.